Deteksi Fraud Kartu Kredit Menggunakan Logistic Regression, Random Forest, XGBoost, dan Agentic AI

Proposal Final Project

Diajukan Untuk Memenuhi

Tugas Final Project

Program Studi Informatika

Universitas Muhammadiyah Malang

Safwa Nusaibah 202310370311002

Shefira Marizcha 202301370311027

Bidang Minat

Sains Data

PROGRAM STUDI INFORMATIKA FAKULTAS TEKNIK

UNIVERSITAS MUHAMMADIYAH MALANG

2026

LEMBAR PERSETUJUAN

Deteksi Fraud Kartu Kredit Menggunakan Logistic Regression, Random Forest, XGBoost, dan Agentic AI

Safwa Nusaibah **Shefira Marizcha**

202310370311002 **202301370311027**

Telah Direkomendasikan Untuk Diajukan Sebagai
Judul Final Project
Mata Kuliah Pembelajaran Mesin
Program Studi Informatika Universitas Muhammadiyah Malang

Malang, 25 Oktober 2026
Menyetujui,

Dosen Pengampu

Dr. Ir. Agus Eko Minarno, S.Kom., M.Kom., IPM., SMIEEE
NIP. 10814100540

DAFTAR ISI

DAFTAR ISI **3**
BAB 1 ..... **5**
PENDAHULUAN **5**
1.1. Pendahuluan 5
1.2. Rumusan Masalah 6
1.3. Tujuan Penelitian 7
1.4. Batasan Masalah 7
BAB 2 ..... **9**
TINJAUAN PUSTAKA **9**
2.1. Konsep Dasar dan Objek Penelitian 9
2.2. Landasan Teori Metode dan Algoritma 9
2.3. Kajian Penelitian Terdahulu yang Relevan 10
2.4. Dasar Evaluasi dan Pengukuran Performa 12
2.5. Sintesis Pustaka dan Dasar Pemilihan Metode 13
BAB III **14**
METODE PENELITIAN **14**
3.1 State of the Art 14
3.2 Rancangan Penelitian 17
3.3 Dataset 18
3.4 Model yang Diusulkan 20
3.4.1 Logistic Regression 20
3.4.2 Random Forest 21
3.4.3 XGBoost 22
3.4.4 Optimasi Threshold 23
3.4.5 Agentic AI 24
3.4.6 Konfigurasi Parameter Model 25
3.5 Pengukuran Performa 27
3.5.1 Confusion Matrix 27
3.5.2 Accuracy 27
3.5.3 Precision 27
3.5.4 Recall 28
3.5.5 F1-score 28
3.5.6 Specificity 28
3.5.7 Precision-Recall Area Under Curve (PR-AUC) 29
3.5.8 Receiver Operating Characteristic Area Under Curve (ROC-AUC) 29
3.5.9 Evaluasi Agentic AI 30
3.6 Skenario Pengujian 30
3.6.1 Skenario 1: Original Dataset 31

3.6.2 Skenario 2: Augmentasi Dataset..... 31
3.6.3 Skenario 3: Preprocessing dan Augmentasi Dataset..... 32
3.6.4 Pengujian Optimasi Threshold..... 34
3.7 Lini masa penelitian..... 35
DAFTAR PUSTAKA.....36

BAB 1

PENDAHULUAN

1.1. Pendahuluan

Perkembangan sistem pembayaran digital telah mendorong peningkatan transaksi kartu kredit secara global seiring dengan pertumbuhan *e-commerce* dan layanan keuangan digital. Kemudahan dan kecepatan transaksi ini memberikan manfaat yang besar bagi pengguna, namun juga membuka peluang bagi pelaku kejahatan untuk melakukan penipuan (*fraud*) [1], [2]. Penipuan transaksi kartu kredit menimbulkan kerugian finansial yang signifikan bagi konsumen, lembaga keuangan, dan *merchant*, serta dapat mengurangi kepercayaan masyarakat terhadap sistem pembayaran digital [3], [4]. Laporan industri menunjukkan bahwa kerugian akibat pembayaran *fraud* di seluruh dunia mencapai puluhan miliar dolar setiap tahun dan diproyeksikan terus meningkat seiring dengan semakin masifnya transaksi digital [5], [6]. Oleh karena itu, pengembangan sistem deteksi *fraud* yang akurat, efisien, dan adaptif menjadi sangat penting untuk mendukung keamanan transaksi dan menjaga stabilitas ekosistem keuangan digital.

Berbagai pendekatan *machine learning* telah banyak digunakan untuk mendeteksi penipuan transaksi kartu kredit. *Logistic Regression* merupakan salah satu metode dasar yang banyak digunakan karena kesederhanaan dan interpretabilitasnya [7], [8]. *Random Forest* terbukti mampu meningkatkan performa melalui pembelajaran *ensemble* dan menangani hubungan *non-linear* antarfitur [9], [10]. *XGBoost* menjadi salah satu metode yang sering memberikan hasil terbaik karena efisiensi dan kemampuannya dalam menangani data kompleks [11], [12]. Selain itu, berbagai penelitian juga mengeksplorasi strategi penyeimbangan kelas seperti *Random Oversampling* dan *Synthetic Minority Over-sampling Technique* (SMOTE) untuk mengatasi ketidakseimbangan kelas yang ekstrem pada data transaksi kartu kredit [13], [14]. Sebagian penelitian menambahkan tahap *preprocessing* yang lebih terstruktur untuk meningkatkan kualitas fitur dan stabilitas model [15], [16]. Di sisi lain, perkembangan *Agentic AI* membuka peluang baru dengan mengintegrasikan model *machine learning* ke dalam sistem yang mampu melakukan penilaian risiko, pengambilan keputusan, dan eksekusi tindakan secara otonom [17], [18]. Beberapa penelitian terbaru mulai menggabungkan model klasifikasi dengan *Large Language Model* (LLM) atau *agent-based framework* untuk mendukung analisis kontekstual dan otomatisasi proses investigasi [19], [20].

Meskipun demikian, masih terdapat beberapa keterbatasan pada penelitian sebelumnya. Pertama, sebagian besar penelitian hanya berfokus pada perbandingan model klasifikasi tanpa mengintegrasikan hasil prediksi ke dalam sistem pengambilan keputusan yang lebih komprehensif [21], [22]. Kedua, strategi penyeimbangan kelas yang digunakan sering kali hanya menerapkan satu teknik *oversampling*, tanpa membandingkan beberapa skenario secara sistematis [23]. Ketiga, penelitian mengenai integrasi model *machine learning* dengan *Agentic AI* masih terbatas dan belum banyak yang mengevaluasi bagaimana hasil prediksi digunakan dalam alur kerja penilaian risiko dan eksekusi tindakan [24]. Selain itu, beberapa penelitian melaporkan performa yang belum optimal pada kelas *fraud*, terutama pada metrik *recall* dan *Precision-Recall Area Under the Curve* (PR-AUC), akibat ketidakseimbangan kelas yang ekstrem [25]. Keterbatasan tersebut menunjukkan perlunya penelitian yang tidak hanya membandingkan performa model klasifikasi dan strategi penyeimbangan kelas, tetapi juga mengkaji pemanfaatan hasil klasifikasi dalam proses penilaian risiko dan pengambilan keputusan.

Berdasarkan permasalahan tersebut, penelitian ini mengusulkan *framework Intelligent Financial Fraud Detection Agent* yang mengintegrasikan *machine learning* dan *Agentic AI* untuk mendeteksi penipuan transaksi kartu kredit. Tiga algoritma *machine learning*, yaitu *Logistic Regression*, *Random Forest*, dan *XGBoost*, akan dibandingkan pada tiga skenario pengujian, yaitu dataset asli, augmentasi, serta *preprocessing* dan augmentasi. Model terbaik kemudian diintegrasikan sebagai *prediction tool* dalam *Agentic AI* yang berfungsi untuk melakukan *risk assessment*, *decision-making*, dan *tool execution*. Hipotesis penelitian ini adalah bahwa kombinasi strategi *preprocessing*, penyeimbangan kelas, dan integrasi model klasifikasi dengan *Agentic AI* berpotensi meningkatkan kemampuan deteksi *fraud*, khususnya pada metrik *recall* dan PR-AUC, sekaligus menghasilkan sistem yang mampu mendukung pengambilan keputusan dan pelaksanaan tindakan secara lebih adaptif berdasarkan hasil prediksi dan kebijakan risiko yang ditetapkan.

1.2. Rumusan Masalah

Berdasarkan latar belakang dan permasalahan yang telah diuraikan pada bagian pendahuluan, rumusan masalah dalam penelitian ini adalah sebagai berikut.

1. Bagaimana membandingkan performa algoritma Logistic Regression, Random Forest, dan XGBoost dalam mendeteksi transaksi kartu kredit yang tergolong normal maupun fraud pada dataset yang memiliki ketidakseimbangan kelas?

2. Bagaimana pengaruh penerapan strategi augmentasi data serta kombinasi preprocessing dan augmentasi terhadap performa deteksi fraud dibandingkan dengan penggunaan dataset asli tanpa augmentasi?
3. Bagaimana menentukan model Machine Learning terbaik berdasarkan metrik evaluasi yang sesuai untuk data tidak seimbang, khususnya Precision, Recall, F1-Score, ROC-AUC, dan PR-AUC?
4. Bagaimana mengintegrasikan model Machine Learning terbaik ke dalam Agentic AI untuk mendukung risk assessment, decision-making, dan tool execution dalam proses penanganan transaksi yang terindikasi fraud?
5. Bagaimana mengevaluasi kinerja Agentic AI berdasarkan kesesuaian penilaian risiko, ketepatan keputusan terhadap kebijakan yang ditetapkan, serta keberhasilan eksekusi tools simulasi?

1.3. Tujuan Penelitian

Tujuan penelitian ini adalah mengembangkan *Intelligent Financial Fraud Detection Agent* untuk mendeteksi penipuan transaksi kartu kredit melalui perbandingan tiga algoritma *Machine Learning*, yaitu Logistic Regression, Random Forest, dan XGBoost, pada tiga skenario pengujian, yaitu dataset asli, augmentasi data, serta kombinasi *preprocessing* dan augmentasi data. Penelitian ini bertujuan untuk menentukan model terbaik berdasarkan metrik evaluasi yang sesuai untuk data dengan ketidakseimbangan kelas, serta mengintegrasikan model terpilih dengan Agentic AI untuk mendukung *risk assessment*, *decision-making*, dan *tool execution*. Kinerja sistem yang dikembangkan selanjutnya dievaluasi berdasarkan performa klasifikasi fraud, kesesuaian penilaian risiko, ketepatan pengambilan keputusan, dan keberhasilan eksekusi *tools* simulasi.

1.4. Batasan Masalah

Agar penelitian lebih terarah dan sesuai dengan rumusan masalah yang telah ditetapkan, batasan masalah dalam penelitian ini adalah sebagai berikut.

1. Penelitian ini berfokus pada deteksi penipuan (*fraud detection*) transaksi kartu kredit menggunakan dataset *Credit Card Fraud Detection* yang bersumber dari Kaggle dan dikaitkan dengan Machine Learning Group, Université Libre de Bruxelles (ULB).
2. Data yang digunakan berbentuk tabular dengan fitur prediktor berupa *Time*, *V1–V28*, dan *Amount*, serta variabel target *Class*, dengan nilai 0 untuk transaksi normal dan nilai 1 untuk transaksi fraud.

3. Algoritma Machine Learning yang dibandingkan dibatasi pada tiga metode, yaitu Logistic Regression, Random Forest, dan XGBoost.
4. Pengujian Machine Learning dilakukan melalui tiga skenario, yaitu penggunaan dataset asli tanpa augmentasi, penggunaan augmentasi data, serta kombinasi preprocessing dan augmentasi data. Strategi augmentasi dan tahapan preprocessing akan ditetapkan sesuai rancangan metodologi penelitian.
5. Evaluasi performa klasifikasi dibatasi pada confusion matrix, Accuracy, Precision, Recall, F1-Score, Specificity, ROC-AUC, dan PR-AUC, dengan perhatian khusus pada kemampuan model dalam mendeteksi transaksi fraud pada kondisi ketidakseimbangan kelas.
6. Model Machine Learning dengan performa terbaik berdasarkan kriteria evaluasi yang ditetapkan akan dipilih untuk diintegrasikan ke dalam Agentic AI sebagai komponen prediksi transaksi.
7. Implementasi Agentic AI dibatasi pada tiga fungsi utama, yaitu *risk assessment*, *decision-making*, dan *tool execution*. Eksekusi tools mencakup simulasi seperti pencarian informasi transaksi (*transaction lookup*), pencatatan kasus investigasi, dan pembuatan laporan.
8. Evaluasi Agentic AI dilakukan secara terpisah dari evaluasi klasifikasi Machine Learning, dengan mengukur kesesuaian kategori risiko terhadap aturan referensi, kesesuaian keputusan terhadap kebijakan risiko, serta keberhasilan pemanggilan tools, ketepatan parameter dan hasil, serta waktu respons.
9. Penelitian ini berfokus pada pengembangan dan pengujian sistem secara eksperimental menggunakan data dan tools simulasi. Penelitian tidak mencakup penerapan langsung pada sistem transaksi perbankan, pemblokiran transaksi secara nyata, maupun pengujian pada lingkungan operasional lembaga keuangan.
10. Penggunaan Large Language Model (LLM) dalam arsitektur Agentic AI belum ditetapkan sebagai komponen wajib dan akan disesuaikan dengan ketentuan penelitian serta kebutuhan implementasi yang telah disepakati.

BAB 2

TINJAUAN PUSTAKA

2.1. Konsep Dasar dan Objek Penelitian

Deteksi penipuan transaksi kartu kredit (*credit card fraud detection*) merupakan permasalahan klasifikasi biner yang bertujuan membedakan transaksi normal dan transaksi fraud berdasarkan karakteristik data transaksi. Dataset yang digunakan berbentuk tabular numerik dengan fitur prediktor Time, V1–V28, dan Amount, serta variabel target Class, dengan nilai 0 untuk transaksi normal dan 1 untuk transaksi fraud. Fitur V1–V28 merupakan hasil transformasi Principal Component Analysis (PCA), sehingga tidak merepresentasikan atribut transaksi yang dapat diinterpretasikan secara langsung. Karakteristik penting dari permasalahan ini adalah ketidakseimbangan kelas (*class imbalance*), yaitu jumlah transaksi normal jauh lebih besar dibandingkan transaksi fraud. Kondisi tersebut dapat menyebabkan model cenderung memprediksi kelas mayoritas, sehingga akurasi saja tidak cukup untuk menggambarkan kemampuan deteksi fraud [1], [2].

Untuk mengatasi permasalahan tersebut, penelitian ini membandingkan Logistic Regression, Random Forest, dan XGBoost dalam mengklasifikasikan transaksi kartu kredit melalui tiga skenario, yaitu penggunaan dataset asli, augmentasi data, serta kombinasi *preprocessing* dan augmentasi. Strategi penyeimbangan kelas, seperti *Random Oversampling* dan SMOTE, dipertimbangkan untuk meningkatkan representasi kelas minoritas pada data pelatihan, dengan efektivitasnya dievaluasi melalui pengujian. Model terbaik selanjutnya diintegrasikan dengan Agentic AI untuk mendukung *risk assessment*, *decision-making*, dan *tool execution* melalui simulasi pencarian informasi transaksi, pencatatan kasus investigasi, dan pembuatan laporan [3], [4].

2.2. Landasan Teori Metode dan Algoritma

Machine Learning merupakan pendekatan kecerdasan buatan yang memungkinkan sistem mempelajari pola dari data untuk menghasilkan prediksi. Dalam penelitian deteksi penipuan transaksi kartu kredit, Machine Learning digunakan untuk mengklasifikasikan transaksi ke dalam kelas normal dan fraud berdasarkan fitur numerik yang tersedia. Penelitian ini menggunakan tiga algoritma, yaitu Logistic Regression, Random Forest, dan XGBoost, untuk membandingkan kemampuan klasifikasi pada data yang memiliki ketidakseimbangan kelas. Logistic Regression memprediksi probabilitas suatu transaksi

termasuk kelas tertentu menggunakan fungsi logistik. Metode ini memiliki keunggulan dalam efisiensi komputasi dan interpretabilitas, tetapi memiliki keterbatasan dalam menangkap hubungan nonlinier secara langsung [5]. Random Forest menggabungkan prediksi dari sejumlah pohon keputusan melalui pendekatan *ensemble learning*, sehingga mampu mempelajari hubungan nonlinier dan mengurangi ketergantungan pada satu pohon. Namun, penggunaan banyak pohon dapat meningkatkan kebutuhan komputasi dan mengurangi kemudahan interpretasi model [6]. Sementara itu, XGBoost membangun pohon keputusan secara bertahap untuk memperbaiki kesalahan prediksi sebelumnya dengan mengoptimalkan fungsi objektif yang mencakup kesalahan prediksi dan regularisasi. Metode ini sesuai untuk data tabular yang memiliki pola kompleks, tetapi performanya bergantung pada konfigurasi parameter dan proses pelatihan [7].

Selain pemilihan algoritma, preprocessing dan penanganan ketidakseimbangan kelas merupakan aspek penting dalam deteksi fraud. Preprocessing dapat mencakup pemeriksaan nilai hilang, nilai tidak valid, duplikasi, dan penskalaan fitur sesuai kebutuhan algoritma. Penyeimbangan kelas dapat dilakukan menggunakan *Random Oversampling*, yaitu mengambil sampel ulang dari kelas minoritas, atau *Synthetic Minority Over-sampling Technique* (SMOTE), yaitu membentuk sampel sintetis berdasarkan interpolasi antarsampel kelas minoritas. Kedua metode tersebut berpotensi membantu model mempelajari pola transaksi fraud, tetapi juga dapat meningkatkan risiko overfitting atau menghasilkan sampel yang kurang representatif. Oleh karena itu, penerapannya perlu dilakukan pada data pelatihan untuk menghindari kebocoran data (*data leakage*) [8], [9]. Model Machine Learning terbaik selanjutnya diintegrasikan dengan Agentic AI, yaitu pendekatan sistem kecerdasan buatan yang mengoordinasikan langkah kerja dan penggunaan tools berdasarkan tujuan serta informasi yang tersedia. Dalam penelitian ini, hasil prediksi berupa label dan probabilitas fraud digunakan untuk mendukung *risk assessment*, *decision-making*, dan *tool execution*, yang mencakup simulasi pencarian informasi transaksi, pencatatan kasus investigasi, dan pembuatan laporan. Evaluasi Agentic AI dilakukan secara terpisah dari evaluasi klasifikasi karena ketepatan prediksi tidak secara otomatis menjamin ketepatan keputusan maupun keberhasilan eksekusi tools [10].

2.3. Kajian Penelitian Terdahulu yang Relevan

Penelitian mengenai deteksi penipuan transaksi kartu kredit telah menggunakan berbagai algoritma *Machine Learning* untuk mengidentifikasi pola transaksi fraud. Pendekatan berbasis Logistic Regression, Random Forest, dan XGBoost menjadi relevan

untuk dikaji karena memiliki prinsip pembelajaran dan karakteristik yang berbeda dalam menangani data tabular. Logistic Regression dapat digunakan sebagai model pembanding yang relatif sederhana, sedangkan Random Forest dan XGBoost memanfaatkan pendekatan *ensemble* untuk mempelajari pola yang lebih kompleks. Perbandingan metode tersebut perlu mempertimbangkan karakteristik dataset, strategi preprocessing, penanganan ketidakseimbangan kelas, serta metrik evaluasi yang digunakan. Penelitian terdahulu yang menggunakan dataset dan kondisi pengujian serupa menjadi acuan penting untuk menentukan metode pembanding dan mengevaluasi hasil penelitian secara objektif [11], [12].

Selain pemilihan algoritma, sejumlah penelitian membahas penanganan ketidakseimbangan kelas melalui *Random Oversampling* dan SMOTE. Kedua pendekatan tersebut bertujuan meningkatkan representasi kelas minoritas dalam proses pelatihan, tetapi menggunakan mekanisme yang berbeda. *Random Oversampling* mengambil ulang sampel kelas minoritas yang telah tersedia, sedangkan SMOTE membentuk sampel sintetis berdasarkan karakteristik sampel minoritas. Perbedaan mekanisme ini menjadi dasar untuk menguji apakah strategi penyeimbangan kelas memberikan pengaruh terhadap kemampuan model mendeteksi transaksi fraud. Perbandingan hasil penelitian terdahulu perlu memperhatikan distribusi kelas, prosedur pembagian data, metode yang digunakan, dan metrik evaluasi agar peningkatan performa tidak disimpulkan hanya berdasarkan nilai akurasi [13], [14].

Perkembangan penelitian selanjutnya juga membuka peluang untuk mengintegrasikan model klasifikasi dengan Agentic AI. Dalam pendekatan ini, hasil prediksi Machine Learning dapat dimanfaatkan sebagai masukan untuk mendukung penilaian risiko, pengambilan keputusan, dan pelaksanaan tindakan melalui tools. Pendekatan tersebut memperluas ruang lingkup sistem dari sekadar menghasilkan prediksi menjadi mendukung alur kerja penanganan transaksi yang terindikasi fraud. Namun, performa klasifikasi dan kemampuan agen perlu dievaluasi secara terpisah karena keberhasilan model mengidentifikasi transaksi fraud tidak secara langsung menjamin ketepatan keputusan atau keberhasilan eksekusi tools [15], [16].

Berdasarkan kelompok penelitian tersebut, penelitian ini diarahkan untuk membandingkan Logistic Regression, Random Forest, dan XGBoost melalui tiga skenario pengujian, yaitu dataset asli, augmentasi, serta kombinasi preprocessing dan augmentasi. Model terbaik berdasarkan kriteria evaluasi yang ditetapkan selanjutnya diintegrasikan dengan Agentic AI untuk mendukung *risk assessment*, *decision-making*, dan *tool execution*.

Perbedaan penelitian ini terletak pada pengujian strategi pengolahan data dan integrasi model klasifikasi dengan agen dalam satu rancangan penelitian, dengan evaluasi klasifikasi dan evaluasi agen dilakukan secara terpisah. Klaim mengenai peningkatan performa dan keunggulan pendekatan ini tetap perlu dibuktikan melalui hasil eksperimen dan dibandingkan dengan penelitian terdahulu yang memiliki kondisi evaluasi sebanding.

2.4. Dasar Evaluasi dan Pengukuran Performa

Evaluasi performa klasifikasi pada deteksi fraud dilakukan untuk mengukur kemampuan model dalam membedakan transaksi normal dan transaksi penipuan. Salah satu dasar evaluasi yang digunakan adalah *confusion matrix*, yang terdiri atas *True Positive* (TP), yaitu transaksi fraud yang terdeteksi dengan benar; *True Negative* (TN), yaitu transaksi normal yang dikenali dengan benar; *False Positive* (FP), yaitu transaksi normal yang salah diklasifikasikan sebagai fraud; dan *False Negative* (FN), yaitu transaksi fraud yang tidak terdeteksi. Berdasarkan komponen tersebut, *Accuracy* mengukur proporsi seluruh prediksi yang benar, *Precision* mengukur proporsi prediksi fraud yang benar-benar fraud, sedangkan *Recall* mengukur proporsi transaksi fraud yang berhasil ditemukan. F1-Score merupakan rata-rata harmonik Precision dan Recall, sehingga membantu menilai keseimbangan keduanya. Sementara itu, *Specificity* mengukur kemampuan model mengenali transaksi normal. Pada dataset yang memiliki ketidakseimbangan kelas, Accuracy saja kurang memadai karena model dapat memperoleh nilai tinggi dengan lebih banyak memprediksi kelas mayoritas, tetapi gagal mendeteksi transaksi fraud [17]..

Selain metrik tersebut, penelitian ini menggunakan *Receiver Operating Characteristic Area Under the Curve* (ROC-AUC) dan *Precision-Recall Area Under the Curve* (PR-AUC) untuk mengevaluasi kemampuan model membedakan kelas pada berbagai ambang keputusan. ROC-AUC mengukur kemampuan diskriminasi model berdasarkan hubungan antara *True Positive Rate* dan *False Positive Rate*, sedangkan PR-AUC merangkum hubungan Precision dan Recall. PR-AUC relevan untuk deteksi fraud karena berfokus pada kualitas identifikasi kelas positif yang jumlahnya jauh lebih sedikit. Nilai metrik yang lebih tinggi umumnya menunjukkan performa yang lebih baik, tetapi interpretasinya tetap harus mempertimbangkan distribusi kelas, ambang keputusan, dan prosedur pengujian yang digunakan [18]. Evaluasi Agentic AI dilakukan secara terpisah melalui tiga indikator, yaitu kesesuaian kategori risiko terhadap aturan referensi, kesesuaian keputusan dengan kebijakan risiko, serta keberhasilan eksekusi tools yang mencakup ketepatan pemanggilan, parameter, hasil, dan waktu respons. Pemisahan evaluasi ini diperlukan karena performa klasifikasi

tidak secara langsung menggambarkan kemampuan agen dalam mengambil keputusan dan menjalankan tindakan. Metrik, prosedur perhitungan, dan skenario pengujian yang digunakan dalam penelitian ditetapkan lebih lanjut pada BAB III.

2.5. Sintesis Pustaka dan Dasar Pemilihan Metode

Berdasarkan kajian teori, deteksi penipuan transaksi kartu kredit menghadapi tantangan berupa ketidakseimbangan kelas yang dapat memengaruhi kemampuan model dalam mengenali transaksi fraud. Oleh karena itu, penelitian ini menggunakan Logistic Regression, Random Forest, dan XGBoost sebagai model pembanding untuk mengevaluasi kemampuan klasifikasi pada data tabular. Penelitian juga membandingkan tiga skenario pengujian, yaitu penggunaan dataset asli, augmentasi data, serta kombinasi *preprocessing* dan augmentasi, untuk mengkaji pengaruh strategi pengolahan data terhadap Precision, Recall, F1-Score, Specificity, ROC-AUC, dan PR-AUC. Selanjutnya, model dengan performa terbaik berdasarkan kriteria evaluasi yang ditetapkan akan diintegrasikan dengan Agentic AI untuk mendukung *risk assessment*, *decision-making*, dan *tool execution*. Evaluasi agen dilakukan secara terpisah berdasarkan kesesuaian penilaian risiko, ketepatan keputusan terhadap kebijakan, serta keberhasilan eksekusi tools simulasi. Melalui rancangan tersebut, penelitian ini akan menguji apakah kombinasi pemilihan model, strategi pengolahan data, dan integrasi Agentic AI dapat menghasilkan deteksi fraud yang lebih baik sekaligus mendukung proses pengambilan keputusan secara terstruktur. Hasil pengujian akan menjadi dasar untuk menilai hipotesis penelitian dan menentukan kontribusi pendekatan yang diusulkan.

BAB III
METODE PENELITIAN

3.1 State of the Art

State of the Art disusun untuk mengidentifikasi perkembangan penelitian terdahulu serta menentukan posisi dan arah pengembangan penelitian yang diusulkan. Kajian dilakukan dengan mempertimbangkan kesesuaian permasalahan, karakteristik dataset, algoritma klasifikasi, teknik penanganan ketidakseimbangan kelas, serta hasil evaluasi yang dilaporkan.

Penelitian ini mengacu pada empat penelitian terdahulu yang memiliki keterkaitan dengan deteksi fraud dan klasifikasi risiko keuangan. Penelitian Sabado dkk. [26] digunakan sebagai referensi utama karena menerapkan dataset European Credit Card Fraud Detection yang sama dengan penelitian ini. Sementara itu, penelitian Komsrimorakot dan Siriborvornratanakul [27], Mapfumo dan Shongwe [28], serta Permai dan Herdianto [29] digunakan sebagai referensi pendukung dalam mengkaji penerapan algoritma klasifikasi dan strategi penanganan ketidakseimbangan data pada domain keuangan dan asuransi. Dataset yang digunakan dalam penelitian ini mengacu pada sumber yang disediakan oleh Machine Learning Group Université Libre de Bruxelles (ULB) melalui Kaggle [30]. Ringkasan penelitian terdahulu yang menjadi dasar pengembangan penelitian disajikan pada Tabel 3.1.

Tabel 3.1 State of the Art Penelitian

No.	Penulis (Tahun)	Judul	Dataset	Metode	Hasil
1	A. C. B. Sabado, E. R. Yu II, dan R. B. Ricafort (2026)	Imbalance-Aware Evaluation and Hyperparameter Optimization of Supervised Machine Learning	European Credit Card Fraud Dataset (284.807 transaksi; 492 Fraud dan 284.315	CRISP-DM, Logistic Regression, Random Forest, XGBoost, SMOTE, Stratified 80:20 Split, GridSearchCV dengan	Accuracy tidak dilaporkan. Hasil setelah SMOTE dan tuning: LR F1 0,18; RF F1 0,82; XGBoost F1 0,81. XGBoost memperoleh

		Models for Credit Card Fraud Detection	Non-Fraud)	Stratified 3-Fold CV, dan optimasi threshold 0,70.	PR-AUC tertinggi 0,817.
2	P. Komsrimorakot dan T. Siriborvornratanakul (2025)	Enhancing Fraud Detection in Imbalanced Motor Insurance Datasets Using CP-SMOTE and Random Under-Sampling	Tiga dataset klaim asuransi kendaraan (Motor Insurance Fraud)	Logistic Regression, Decision Tree, Random Forest, SVM, XGBoost, dan AdaBoost. Teknik resampling: CP-SMOTE, SMOTE, ENN, ADASYN, Random Under-Sampling,	CP-SMOTE + RUS: Logistic Regression 64,16%; Random Forest 66,28%; XGBoost 69,09%.
3	I. Mapfumo dan T. Shongwe (2026)	Performance Evaluation of Machine Learning and Deep Learning Models for Credit Risk Prediction	German Credit Dataset dan Taiwanese Credit Dataset	Logistic Regression, Decision Tree, SVM, Random Forest, AdaBoost, XGBoost, MLP, CNN, LSTM, dan GRU. Teknik resampling: SMOTE, ENN, dan	SMOTE-ENN + MLP memperoleh akurasi 95,4% pada German Credit; SMOTE-ENN + Random Forest memperoleh akurasi 82,1% pada Taiwanese Credit

				SMOTE-ENN. Interpretabilitas menggunakan SHAP.	
4	S. D. Permai dan K. Herdianto (2023)	Prediction of Health Insurance Claims Using Logistic Regression and XGBoost Methods	Data historis klaim asuransi kesehatan dari perusahaan asuransi di Indonesia; 11.882 data awal dan 10.900 data setelah preprocessing	Logistic Regression dan XGBoost. Preprocessing berupa penghapusan missing value. Pembagian data training dan testing sebesar 60:40. Optimasi hyperparameter XGBoost menggunakan eta, gamma, max depth, subsample, dan column sample.	Logistic Regression memperoleh Accuracy 83,44%, Precision 48,57%, dan Recall 4,72%. XGBoost memperoleh Accuracy 85,25%, Precision 65,10%, dan Recall 23,06%.

Berdasarkan Tabel 3.1, penelitian terdahulu menunjukkan bahwa algoritma Logistic Regression, Random Forest, dan XGBoost telah digunakan dalam berbagai permasalahan klasifikasi pada domain keuangan dan asuransi. Penelitian Sabado et, all. [26] memiliki kesamaan paling kuat dengan penelitian ini karena menggunakan dataset dan algoritma yang sama. Penelitian tersebut juga menunjukkan bahwa penanganan ketidakseimbangan kelas melalui SMOTE dapat memengaruhi hasil evaluasi model.

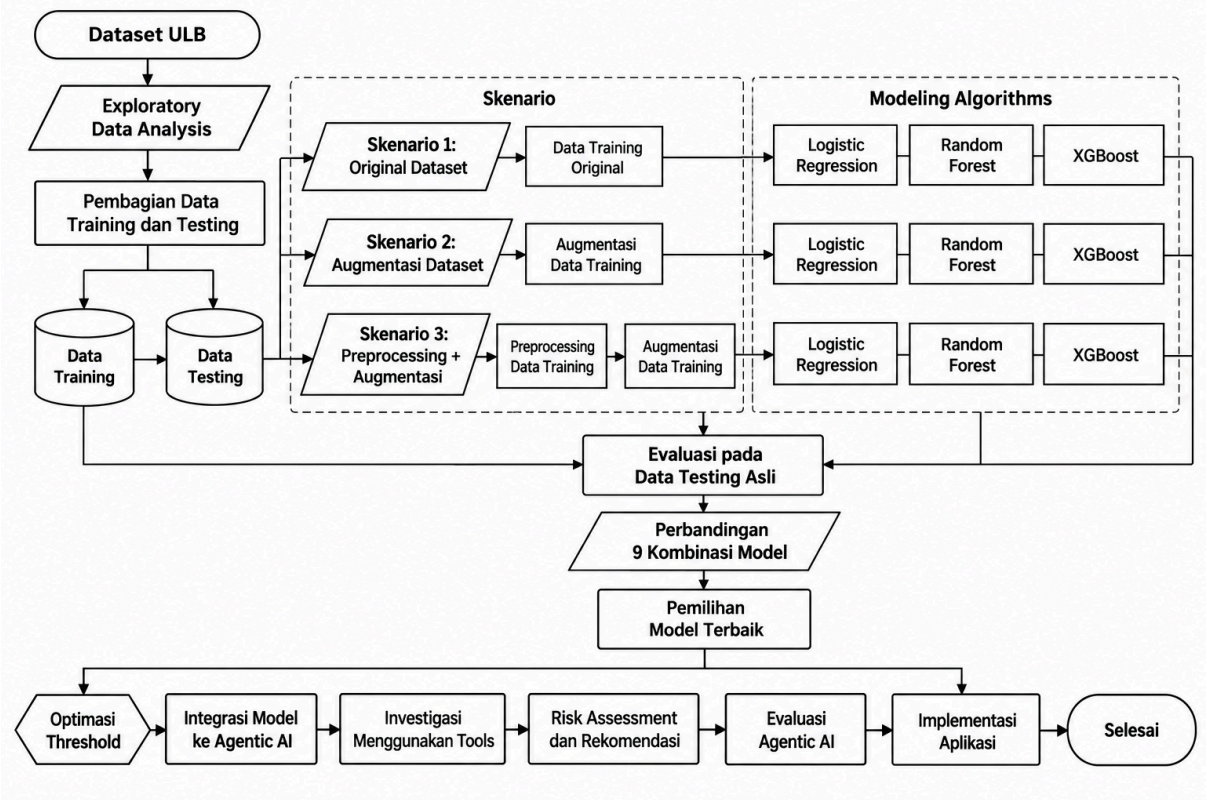
Meskipun demikian, penelitian ini memiliki fokus pengembangan yang berbeda. Pengujian tidak hanya dilakukan untuk membandingkan algoritma klasifikasi, tetapi juga untuk mengetahui pengaruh tiga skenario pengolahan data terhadap performa model. Selain

itu, model dengan performa terbaik akan diintegrasikan dengan Agentic AI sebagai lapisan investigasi yang memanfaatkan hasil prediksi dan tools pendukung untuk menghasilkan rekomendasi keputusan terhadap transaksi.

3.2 Rancangan Penelitian

Penelitian ini menggunakan pendekatan kuantitatif dengan metode eksperimental untuk mengembangkan sistem deteksi transaksi kartu kredit yang terindikasi fraud. Metode eksperimental dilakukan dengan membandingkan performa tiga algoritma Machine Learning, yaitu Logistic Regression, Random Forest, dan XGBoost, pada tiga skenario pengolahan data.

Secara umum, tahapan penelitian dimulai dari studi literatur dan pengumpulan dataset, dilanjutkan dengan eksplorasi data, persiapan data, pembagian data, pembangunan model klasifikasi, serta evaluasi performa. Pengujian model dilakukan melalui tiga skenario, yaitu penggunaan dataset asli, penggunaan augmentasi data, dan kombinasi preprocessing dengan augmentasi data. Alur penelitian secara keseluruhan ditampilkan pada Gambar 3.1.



Gambar 3.1 Rancangan Penelitian

Berdasarkan Gambar 3.1, penelitian diawali dengan studi literatur untuk memperoleh landasan teoritis dan mengidentifikasi metode yang relevan dengan permasalahan deteksi fraud. Dataset European Credit Card Fraud Detection selanjutnya digunakan sebagai sumber data eksperimen. Tahap eksplorasi data dilakukan untuk mengetahui karakteristik atribut, distribusi kelas, serta kondisi data yang akan digunakan dalam proses pemodelan.

Setelah tahap eksplorasi, data dibagi menjadi data training, validation, dan testing sesuai rancangan eksperimen. Data training digunakan dalam tiga skenario pengujian. Skenario pertama menggunakan dataset asli tanpa augmentasi, skenario kedua menerapkan augmentasi pada data training, sedangkan skenario ketiga menerapkan preprocessing yang dilanjutkan dengan augmentasi pada data training. Setiap skenario akan diuji menggunakan Logistic Regression, Random Forest, dan XGBoost.

Hasil pelatihan model selanjutnya dievaluasi menggunakan data testing yang mempertahankan distribusi kelas asli. Evaluasi dilakukan untuk membandingkan kemampuan setiap model dalam mengidentifikasi transaksi fraud dan transaksi normal. Model terpilih kemudian melalui tahap optimasi threshold menggunakan data validation sebelum diintegrasikan ke dalam Agentic AI. Pada tahap integrasi, Agentic AI akan memanfaatkan model prediksi dan tools yang tersedia untuk melakukan analisis transaksi, penilaian risiko, serta penyusunan rekomendasi keputusan. Tahap akhir penelitian meliputi evaluasi proses investigasi Agentic AI dan implementasi sistem dalam bentuk aplikasi.

3.3 Dataset

Dataset yang digunakan dalam penelitian ini adalah Credit Card Fraud Detection yang tersedia pada platform Kaggle dan disediakan oleh Machine Learning Group dari Université Libre de Bruxelles (ULB) [30]. Dataset tersebut berisi transaksi kartu kredit yang dilakukan oleh pemegang kartu di Eropa pada September 2013. Dataset ini juga digunakan dalam penelitian Sabado dkk. [26], sehingga memungkinkan penelitian ini menggunakan sumber data yang sama sebagai dasar pengembangan dan perbandingan hasil eksperimen.

Dataset terdiri atas 284.807 transaksi dan 31 kolom, yang mencakup 30 atribut prediktor serta satu atribut target. Atribut target bernama Class yang menunjukkan kategori transaksi, yaitu transaksi normal dengan label 0 dan transaksi fraud dengan label 1. Karakteristik dataset yang digunakan dalam penelitian disajikan pada Tabel 3.2.

Tabel 3.2 Karakteristik Dataset

Karakteristik	Keterangan
Jumlah data	284.807 transaksi
Jumlah atribut	31 kolom
Atribut prediktor	30 atribut
Atribut target	Class
Kelas 0	Transaksi normal
Kelas 1	Transaksi fraud
Jumlah transaksi normal	284.315
Jumlah transaksi fraud	492
Persentase transaksi fraud	0,1727%

Berdasarkan Tabel 3.2, dataset memiliki distribusi kelas yang sangat tidak seimbang. Transaksi Non-Fraud berjumlah 284.315, sedangkan transaksi Fraud hanya berjumlah 492 atau sekitar 0,1727% dari keseluruhan data. Ketidakseimbangan tersebut menjadi salah satu pertimbangan dalam menentukan strategi pengolahan data dan metrik evaluasi, khususnya untuk mengukur kemampuan model dalam mendeteksi kelas minoritas.

Atribut pada dataset terdiri atas Time, V1 sampai V28, Amount, dan Class. Atribut V1 sampai V28 merupakan hasil transformasi Principal Component Analysis (PCA) untuk menjaga kerahasiaan informasi transaksi. Atribut Time menunjukkan waktu relatif transaksi, sedangkan Amount menunjukkan nominal transaksi [30]. Penjelasan masing-masing atribut ditampilkan pada Tabel 3.3.

Tabel 3.3 Atribut Dataset

Atribut	Keterangan
Time	Waktu transaksi dalam satuan detik relatif terhadap transaksi pertama
V1–V28	Atribut hasil transformasi Principal Component Analysis (PCA)
Amount	Nominal transaksi
Class	Label kelas transaksi, yaitu 0 untuk normal dan 1 untuk fraud

Dalam penelitian ini, atribut Class akan digunakan sebagai variabel target, sedangkan atribut lainnya digunakan sebagai variabel prediktor. Sebelum proses pemodelan, dataset akan diperiksa untuk mengetahui keberadaan missing value, data duplikat, serta karakteristik setiap atribut. Hasil pemeriksaan tersebut akan menjadi dasar dalam menentukan tahapan preprocessing yang diperlukan.

3.4 Model yang Diusulkan

Penelitian ini mengusulkan sistem deteksi transaksi kartu kredit yang mengintegrasikan algoritma Machine Learning dengan Agentic AI. Algoritma Machine Learning digunakan untuk melakukan klasifikasi transaksi berdasarkan karakteristik data yang tersedia, sedangkan Agentic AI digunakan sebagai lapisan investigasi dan pendukung pengambilan keputusan berdasarkan hasil prediksi model. Tiga algoritma yang akan diterapkan adalah Logistic Regression, Random Forest, dan XGBoost. Ketiga algoritma tersebut dipilih untuk membandingkan pendekatan klasifikasi linear dan ensemble dalam mendeteksi transaksi fraud.

3.4.1 Logistic Regression

Logistic Regression merupakan algoritma supervised learning yang digunakan untuk menyelesaikan permasalahan klasifikasi biner. Algoritma ini memodelkan probabilitas suatu data termasuk ke dalam kelas tertentu menggunakan fungsi logistik atau sigmoid. Pada penelitian ini, Logistic Regression digunakan untuk memperkirakan probabilitas transaksi termasuk kelas Fraud. Probabilitas transaksi termasuk kelas Fraud dirumuskan sebagai berikut:

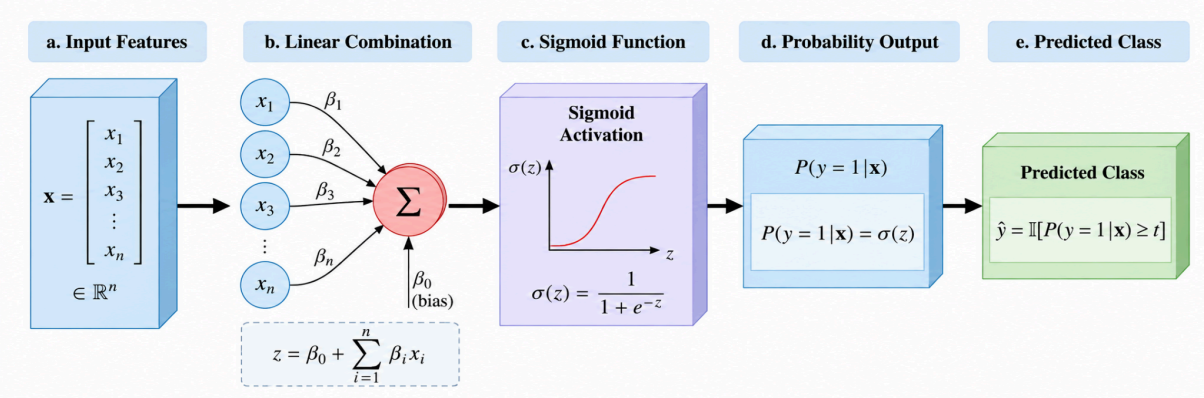
$$P(y = 1 \mid x) = \frac{1}{1 + e^{-(\beta_0 + \sum_{i=1}^{n} \beta_i x_i)}}$$

Keterangan:

1. $P(y = 1 \mid x)$: probabilitas transaksi termasuk kelas Fraud.
2. β_0: konstanta atau intercept.
3. β_j: koefisien regresi atribut ke-j.
4. x_j: nilai atribut ke-j.

5. p: jumlah atribut prediktor.
6. e: bilangan eksponensial.

Arsitektur Logistic Regression yang digunakan dalam penelitian ditunjukkan pada Gambar 3.2.



Gambar 3.2 Arsitektur Model Logistic Regression

Berdasarkan Gambar 3.2, proses klasifikasi dimulai dari input fitur transaksi yang diteruskan ke proses kombinasi linear. Hasil kombinasi linear selanjutnya diproses menggunakan fungsi sigmoid untuk menghasilkan probabilitas kelas. Probabilitas tersebut kemudian dibandingkan dengan threshold untuk menentukan hasil klasifikasi transaksi sebagai Non-Fraud atau Fraud.

3.4.2 Random Forest

Random Forest merupakan algoritma ensemble learning yang menggabungkan sejumlah decision tree untuk menghasilkan prediksi klasifikasi. Setiap pohon dibangun berdasarkan sampel data dan subset atribut tertentu. Hasil prediksi diperoleh melalui agregasi prediksi dari seluruh pohon yang membentuk model. Prediksi probabilitas kelas dapat dirumuskan sebagai berikut:

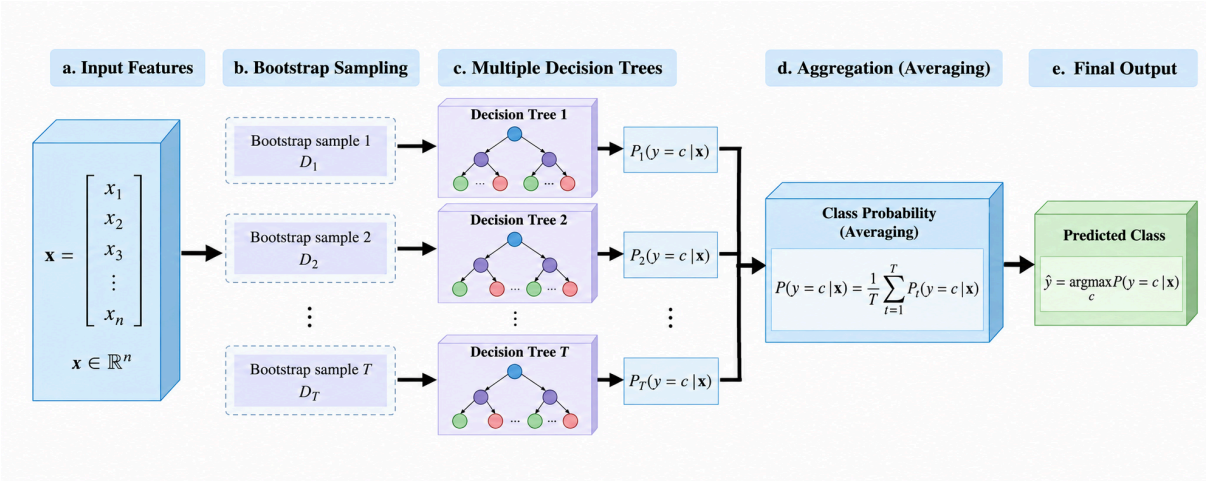
$$P(y = c \mid x) = \frac{1}{T} \sum_{t=1}^{T} P_t(y = c \mid x)$$

Keterangan:

1. $P(y = c \mid x)$: probabilitas data x termasuk kelas c.

2. T: jumlah pohon keputusan.
3. $P_t(y = c \mid x)$: probabilitas kelas c dari pohon ke-t.

Arsitektur Random Forest yang digunakan dalam penelitian ditunjukkan pada Gambar 3.3.



Gambar 3.3 Arsitektur Model Random Forest

Berdasarkan Gambar 3.3, data transaksi digunakan sebagai input yang selanjutnya diproses melalui beberapa pohon keputusan. Setiap pohon menghasilkan prediksi kelas berdasarkan pola atribut yang dipelajari. Hasil prediksi dari seluruh pohon kemudian digabungkan melalui proses agregasi untuk memperoleh probabilitas kelas akhir yang digunakan dalam menentukan transaksi Non-Fraud atau Fraud.

3.4.3 XGBoost

Extreme Gradient Boosting (XGBoost) merupakan algoritma ensemble learning berbasis gradient boosting yang membangun model secara bertahap. Setiap model baru digunakan untuk memperbaiki kesalahan prediksi model sebelumnya melalui proses optimasi fungsi objektif. Fungsi objektif XGBoost secara umum dirumuskan sebagai berikut:

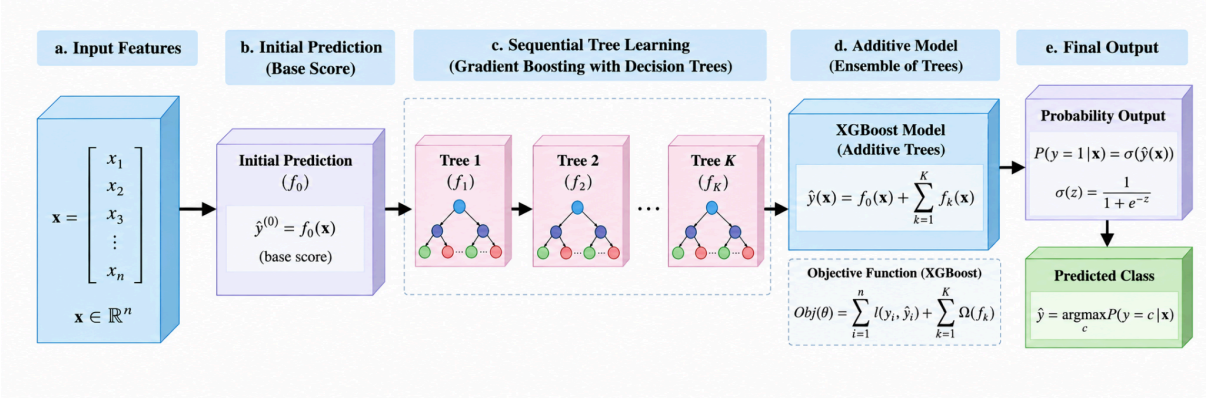
$$Obj(\theta) = \sum_{i=1}^{n} l(y_i, \hat{y}_i) + \sum_{k=1}^{K} \Omega(f_k)$$

Keterangan:

1. $Obj(\theta)$: fungsi objektif model.

2. n: jumlah data training.
3. y_i: label aktual data ke-i.
4. $\hat{y}_i$: hasil prediksi data ke-i.
5. l: fungsi loss yang mengukur kesalahan prediksi.
6. K: jumlah pohon keputusan.
7. f_k: pohon keputusan ke-k.
8. $\Omega(f_k)$: komponen regularisasi untuk mengendalikan kompleksitas model.

Arsitektur XGBoost yang digunakan dalam penelitian ditunjukkan pada Gambar 3.4.



Gambar 3.4 Arsitektur Model XGBoost

Berdasarkan Gambar 3.4, proses pemodelan dimulai dari data transaksi yang digunakan untuk menghasilkan prediksi awal. Selanjutnya, beberapa pohon keputusan dibangun secara bertahap untuk memperbaiki kesalahan prediksi sebelumnya. Hasil dari setiap tahapan boosting digabungkan melalui proses agregasi sehingga menghasilkan probabilitas klasifikasi akhir.

3.4.4 Optimasi Threshold

Selain pembangunan model klasifikasi, penelitian ini menerapkan optimasi threshold untuk menentukan batas probabilitas dalam mengklasifikasikan transaksi menjadi kelas Non-Fraud atau Fraud. Model klasifikasi menghasilkan probabilitas yang selanjutnya dibandingkan dengan nilai threshold untuk menentukan kelas prediksi. Secara umum, aturan klasifikasi dituliskan sebagai berikut:

$$\hat{y} = \begin{cases} 1, & P(y = 1 \mid x) \geq t \\ 0, & P(y = 1 \mid x) < t \end{cases}$$

Keterangan:

1. $\hat{y}$: kelas hasil prediksi.
2. $P(y = 1 \mid x)$: probabilitas transaksi termasuk Fraud.
3. t: nilai threshold klasifikasi.

Threshold default sebesar 0,50 digunakan sebagai nilai pembanding. Selanjutnya, beberapa nilai threshold alternatif diuji menggunakan data validation untuk mengetahui pengaruh perubahan batas klasifikasi terhadap Precision, Recall, F1-Score, serta jumlah False Positive dan False Negative. Nilai threshold terpilih ditentukan berdasarkan kriteria evaluasi yang digunakan dalam penelitian. Proses pemilihan threshold hanya dilakukan menggunakan data validation, sedangkan data testing digunakan untuk evaluasi akhir agar tidak terjadi kebocoran informasi pengujian.

3.4.5 Agentic AI

Agentic AI akan dikembangkan sebagai lapisan investigasi dan pendukung pengambilan keputusan yang memanfaatkan hasil prediksi model Machine Learning. Komponen ini tidak menggantikan fungsi model klasifikasi, melainkan menggunakan keluaran model sebagai dasar untuk menentukan langkah investigasi berikutnya. Arsitektur Agentic AI yang diusulkan terdiri atas beberapa komponen berikut. Arsitektur Agentic AI yang diusulkan terdiri atas beberapa komponen yang dijelaskan pada Tabel 3.4.

Tabel 3.4 Komponen Agentic AI

Komponen	Fungsi
Agent Orchestrator	Mengelola alur kerja dan menentukan langkah investigasi berdasarkan kondisi transaksi
ML Prediction Tool	Memanggil model Machine Learning untuk memperoleh hasil prediksi dan probabilitas fraud
Threshold Analysis Tool	Mengevaluasi probabilitas transaksi berdasarkan nilai threshold yang telah ditentukan
Transaction Analysis Tool	Menganalisis atribut transaksi yang tersedia sebagai informasi pendukung

Komponen	Fungsi
Risk Assessment Tool	Menggabungkan hasil prediksi dan analisis untuk menentukan tingkat risiko transaksi
Decision Tool	Menghasilkan rekomendasi tindakan berdasarkan hasil investigasi
Audit Log	Mencatat pemanggilan tools, hasil analisis, dan rekomendasi yang dihasilkan agent

Berdasarkan Tabel 3.4, Agent Orchestrator bertugas mengelola proses investigasi dan menentukan tools yang diperlukan. ML Prediction Tool digunakan untuk memperoleh prediksi transaksi, sedangkan Threshold Analysis Tool mengevaluasi probabilitas berdasarkan batas klasifikasi yang telah ditetapkan. Transaction Analysis Tool dan Risk Assessment Tool selanjutnya digunakan untuk mendukung analisis transaksi dan penentuan tingkat risiko.

Proses kerja Agentic AI dimulai ketika sistem menerima data transaksi sebagai masukan. Agent Orchestrator kemudian mengatur proses investigasi dengan memanggil ML Prediction Tool untuk memperoleh hasil klasifikasi dan probabilitas Fraud. Berdasarkan hasil tersebut, agent menentukan kebutuhan analisis tambahan melalui tools yang tersedia.

Hasil pemanggilan tools digunakan sebagai informasi pendukung dalam proses penilaian risiko. Selanjutnya, Decision Tool menghasilkan rekomendasi berupa kategori risiko rendah, perlu ditinjau, atau risiko tinggi. Seluruh proses investigasi dan hasil pemanggilan tools dicatat melalui Audit Log agar alur pengambilan keputusan dapat ditelusuri.

Catatan metodologis: agar implementasi benar-benar dapat disebut Agentic AI, Agent Orchestrator harus memiliki kemampuan menentukan langkah atau pemanggilan tools berdasarkan konteks dan hasil sebelumnya. Jika seluruh proses hanya berjalan melalui urutan aturan tetap, komponen tersebut lebih tepat disebut sistem berbasis aturan.

3.4.6 Konfigurasi Parameter Model

Proses pemodelan dilakukan menggunakan tiga algoritma klasifikasi, yaitu Logistic Regression, Random Forest, dan XGBoost. Setiap algoritma memiliki parameter yang mengatur proses pembelajaran dan karakteristik model. Penentuan parameter dilakukan untuk memperoleh konfigurasi model yang sesuai dengan karakteristik dataset dan tujuan

klasifikasi transaksi Fraud. Parameter yang digunakan pada setiap algoritma ditentukan melalui proses pengujian konfigurasi model. Parameter utama yang dipertimbangkan dalam penelitian ini disajikan pada Tabel 3.5.

Tabel 3.5 Parameter Model Machine Learning

Model	Parameter	Fungsi
Logistic Regression	C	Mengatur kekuatan regularisasi
	solver	Menentukan algoritma optimasi
	max_iter	Menentukan jumlah iterasi maksimum
	class_weight	Mengatur bobot kelas dalam proses pembelajaran
Random Forest	n_estimators	Menentukan jumlah pohon keputusan
	max_depth	Membatasi kedalaman pohon
	min_samples_split	Menentukan jumlah minimum sampel untuk membagi node
	class_weight	Mengatur bobot kelas
XGBoost	n_estimators	Menentukan jumlah tahapan boosting atau pohon
	max_depth	Mengatur kedalaman maksimum pohon
	learning_rate	Mengatur kontribusi setiap pohon terhadap model
	subsample	Menentukan proporsi sampel yang digunakan untuk membangun setiap pohon
	colsample_bytree	Menentukan proporsi fitur yang digunakan pada setiap

Nilai parameter ditentukan melalui pengujian konfigurasi model pada data training dan validation. Konfigurasi terbaik dipilih berdasarkan hasil evaluasi pada data validation dengan mempertimbangkan kemampuan model dalam mendeteksi kelas Fraud. Konfigurasi tersebut selanjutnya digunakan untuk melakukan evaluasi akhir pada data testing.

3.5 Pengukuran Performa

Pengukuran performa dilakukan untuk mengetahui kemampuan model Machine Learning dalam mengklasifikasikan transaksi Non-Fraud dan Fraud. Evaluasi dilakukan menggunakan hasil prediksi terhadap data testing yang memiliki distribusi kelas asli. Selain evaluasi model klasifikasi, penelitian ini juga melakukan pengujian terhadap Agentic AI untuk mengetahui kemampuannya dalam menjalankan proses investigasi, menggunakan tools, serta menghasilkan rekomendasi keputusan.

3.5.1 Confusion Matrix

Confusion matrix digunakan untuk membandingkan hasil prediksi model dengan label aktual. Pada klasifikasi fraud, confusion matrix terdiri atas empat komponen, yaitu True Positive, True Negative, False Positive, dan False Negative. Penjelasan setiap komponen ditampilkan pada Tabel 3.5.

Tabel 3.5 Komponen Confusion Matrix

Komponen	**Keterangan**
True Positive (TP)	Transaksi fraud yang berhasil diprediksi sebagai fraud
True Negative (TN)	Transaksi normal yang berhasil diprediksi sebagai normal
False Positive (FP)	Transaksi normal yang salah diprediksi sebagai fraud
False Negative (FN)	Transaksi fraud yang salah diprediksi sebagai normal

Berdasarkan Tabel 3.5, TP dan TN menunjukkan jumlah prediksi yang benar, sedangkan FP dan FN menunjukkan jumlah kesalahan klasifikasi. Keempat komponen tersebut digunakan sebagai dasar perhitungan metrik evaluasi berikutnya.

3.5.2 Accuracy

Accuracy digunakan untuk mengukur proporsi seluruh prediksi yang benar terhadap jumlah keseluruhan data. Nilai Accuracy dirumuskan sebagai berikut:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

3.5.3 Precision

Precision digunakan untuk mengukur proporsi transaksi yang diprediksi sebagai Fraud dan benar-benar merupakan transaksi Fraud. Nilai Precision dirumuskan sebagai berikut:

$$Precision = \frac{TP}{TP + FP}$$

3.5.4 Recall

Recall atau Sensitivity digunakan untuk mengukur kemampuan model dalam menemukan seluruh transaksi Fraud yang sebenarnya. Nilai Recall dirumuskan sebagai berikut:

$$Recall = \frac{TP}{TP + FN}$$

3.5.5 F1-score

F1-Score merupakan rata-rata harmonis antara Precision dan Recall sehingga dapat digunakan untuk mengevaluasi keseimbangan kedua metrik tersebut. Nilai F1-Score dirumuskan sebagai berikut:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Dalam penelitian ini, F1-Score kelas Fraud menjadi salah satu metrik utama karena penelitian berfokus pada kemampuan model dalam mendeteksi transaksi Fraud yang memiliki jumlah jauh lebih sedikit dibandingkan transaksi Non-Fraud.

3.5.6 Specificity

Specificity digunakan untuk mengukur kemampuan model dalam mengidentifikasi transaksi Non-Fraud dengan benar. Nilai Specificity dirumuskan sebagai berikut:

$$Specificity = \frac{TN}{TN + FP}$$

3.5.7 Precision-Recall Area Under Curve (PR-AUC)

Precision-Recall Area Under Curve (PR-AUC) digunakan untuk mengukur performa model berdasarkan hubungan antara Precision dan Recall pada berbagai nilai threshold. Metrik ini digunakan sebagai evaluasi tambahan karena dataset yang digunakan memiliki distribusi kelas yang sangat tidak seimbang. PR-AUC diperoleh dari luas area di bawah kurva Precision-Recall. Semakin tinggi nilai PR-AUC, semakin baik kemampuan model dalam mempertahankan hubungan Precision dan Recall pada berbagai threshold.

$$PR\text{-}AUC = \int_0^1 Precision(Recall)\, d(Recall)$$

3.5.8 Receiver Operating Characteristic Area Under Curve (ROC-AUC)

ROC-AUC digunakan untuk mengukur kemampuan model dalam membedakan kelas Non-Fraud dan Fraud pada berbagai nilai threshold. Kurva ROC dibentuk berdasarkan hubungan antara True Positive Rate (TPR) dan False Positive Rate (FPR). Nilai ROC-AUC menunjukkan luas area di bawah kurva ROC, dengan nilai yang semakin mendekati 1 menunjukkan kemampuan pemisahan kelas yang semakin baik. Nilai TPR dan FPR dirumuskan sebagai berikut:

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{FP + TN}$$

Nilai ROC-AUC digunakan sebagai metrik tambahan untuk mengevaluasi kemampuan diskriminasi model pada berbagai threshold. Penggunaan ROC-AUC dilengkapi dengan PR-AUC karena dataset memiliki distribusi kelas yang tidak seimbang.

3.5.9 Evaluasi Agentic AI

Selain mengevaluasi performa klasifikasi, penelitian ini melakukan pengujian terhadap kemampuan Agentic AI dalam menjalankan proses investigasi transaksi. Evaluasi dilakukan secara terpisah dari evaluasi model Machine Learning karena keduanya memiliki fungsi dan keluaran yang berbeda. Aspek evaluasi Agentic AI meliputi ketepatan pemilihan tools, keberhasilan eksekusi, ketepatan rekomendasi, kelengkapan investigasi, konsistensi respons, dan waktu pemrosesan. Aspek tersebut dijelaskan pada Tabel 3.6.

Tabel 3.6 Aspek Pengukuran Evaluasi Agentic AI

Aspek	Pengukuran
Tool Selection Accuracy	Ketepatan agent dalam memilih tools sesuai kebutuhan investigasi
Tool Execution Success	Keberhasilan agent dalam menjalankan tools yang dipilih
Decision Accuracy	Kesesuaian rekomendasi agent dengan keputusan acuan
Investigation Completeness	Kelengkapan tahapan investigasi berdasarkan skenario pengujian
Response Consistency	Konsistensi rekomendasi pada input dan kondisi pengujian yang sama
Processing Time	Waktu yang dibutuhkan agent untuk menyelesaikan proses investigasi

Berdasarkan Tabel 3.6, evaluasi Agentic AI dilakukan dengan mengamati setiap tahapan investigasi dan keluaran yang dihasilkan. Pengukuran setiap aspek dilakukan berdasarkan skenario pengujian dan kriteria penilaian yang ditetapkan sebelum pengujian dilaksanakan.

3.6 Skenario Pengujian

Skenario pengujian dilakukan untuk mengetahui pengaruh penerapan augmentasi dan preprocessing terhadap performa algoritma Machine Learning dalam mendeteksi transaksi kartu kredit yang terindikasi Fraud. Pengujian menggunakan tiga algoritma klasifikasi, yaitu

Logistic Regression, Random Forest, dan XGBoost, yang diterapkan pada tiga skenario pengolahan data.

Sebelum eksperimen dilakukan, dataset dibagi menjadi data training, validation, dan testing menggunakan metode stratified split untuk mempertahankan proporsi kelas Non-Fraud dan Fraud pada setiap subset. Pembagian dataset dilakukan satu kali dan hasil pembagian yang sama digunakan pada seluruh skenario agar perbandingan performa model dapat dilakukan secara konsisten.

Proses preprocessing dan augmentasi hanya diterapkan pada data training. Data validation digunakan untuk pemilihan konfigurasi model dan optimasi threshold, sedangkan data testing tidak digunakan dalam proses preprocessing yang mempelajari parameter data, augmentasi, pelatihan model, maupun optimasi threshold. Dengan demikian, data testing tetap mempertahankan distribusi kelas asli dan digunakan untuk mengevaluasi kemampuan generalisasi model.

3.6.1 Skenario 1: Original Dataset

Skenario pertama menguji kemampuan klasifikasi menggunakan dataset asli tanpa penerapan augmentasi dan preprocessing tambahan. Data training digunakan untuk melatih model Logistic Regression, Random Forest, dan XGBoost. Selanjutnya, data validation digunakan untuk mengevaluasi konfigurasi model dan menentukan threshold, sedangkan data testing digunakan untuk mengukur performa akhir. Skenario ini berfungsi sebagai baseline untuk mengetahui performa awal ketiga algoritma terhadap distribusi kelas asli pada dataset.

3.6.2 Skenario 2: Augmentasi Dataset

Skenario kedua menguji pengaruh augmentasi terhadap performa model dalam menangani ketidakseimbangan kelas. Proses augmentasi diterapkan hanya pada data training sehingga jumlah sampel kelas Fraud dapat ditingkatkan tanpa mengubah distribusi kelas pada data validation dan testing. Data training hasil augmentasi selanjutnya digunakan untuk melatih Logistic Regression, Random Forest, dan XGBoost. Hasil pengujian dibandingkan dengan skenario pertama untuk mengetahui perubahan performa model setelah penerapan augmentasi.

3.6.3 Skenario 3: Preprocessing dan Augmentasi Dataset

Skenario ketiga menguji kombinasi preprocessing dan augmentasi terhadap performa model klasifikasi. Tahapan preprocessing dilakukan pada data training untuk mempersiapkan atribut agar sesuai dengan kebutuhan pengolahan model. Setelah proses preprocessing selesai, augmentasi diterapkan pada data training untuk menangani ketidakseimbangan kelas. Data training hasil preprocessing dan augmentasi selanjutnya digunakan untuk melatih Logistic Regression, Random Forest, dan XGBoost. Data validation dan testing diproses menggunakan transformasi yang telah dipelajari dari data training, tanpa dilakukan augmentasi. Skenario ini bertujuan untuk mengetahui pengaruh kombinasi preprocessing dan augmentasi terhadap kemampuan model dalam mendeteksi transaksi Fraud.

Tabel 3.7 Rancangan Skenario Pengujian

Skenario	Data	Perlakuan	Model
Original Dataset	Data training asli	Tanpa augmentasi dan preprocessing tambahan	LR, RF, XGBoost
Augmentasi Dataset	Data training	Augmentasi untuk menangani ketidakseimbangan kelas	LR, RF, XGBoost
Preprocessing dan Augmentasi	Data training	Preprocessing dilanjutkan dengan augmentasi	LR, RF, XGBoost

Keterangan: Seluruh skenario menggunakan pembagian data training, validation, dan testing yang sama. Augmentasi hanya diterapkan pada data training, sedangkan data validation dan testing tetap mempertahankan distribusi kelas asli.

Berdasarkan Tabel 3.7, pengujian dilakukan melalui tiga skenario dengan perlakuan pengolahan data yang berbeda. Setiap skenario diterapkan pada tiga algoritma klasifikasi, yaitu Logistic Regression, Random Forest, dan XGBoost, sehingga menghasilkan sembilan kombinasi pengujian. Hasil dari setiap kombinasi selanjutnya dibandingkan menggunakan metrik evaluasi yang telah ditentukan untuk memperoleh model dan skenario dengan performa terbaik.

Tabel 3.7. Perbandingan Hasil Pengujian Model pada Setiap Skenario

Skenario	Model	Class/Label	TP	TN	FP	FN	Precision (%)	Recall (%)	F1-Score (%)	Accuracy (%)	Specificity (%)	ROC-AUC	PR-AUC
1	Logistic Regression	Non-Fraud	–	–	–	–	–	–	–	–	–	–	–
		Fraud	–	–	–	–	–	–	–	–	–	–	–
1	Random Forest	Non-Fraud	–	–	–	–	–	–	–	–	–	–	–
		Fraud	–	–	–	–	–	–	–	–	–	–	–
1	XGBoost	Non-Fraud	–	–	–	–	–	–	–	–	–	–	–
		Fraud	–	–	–	–	–	–	–	–	–	–	–
2	Logistic Regression	Non-Fraud	–	–	–	–	–	–	–	–	–	–	–
		Fraud	–	–	–	–	–	–	–	–	–	–	–
2	Random Forest	Non-Fraud	–	–	–	–	–	–	–	–	–	–	–
		Fraud	–	–	–	–	–	–	–	–	–	–	–
2	XGBoost	Non-Fraud	–	–	–	–	–	–	–	–	–	–	–
		Fraud	–	–	–	–	–	–	–	–	–	–	–
3	Logistic Regression	Non-Fraud	–	–	–	–	–	–	–	–	–	–	–
		Fraud	–	–	–	–	–	–	–	–	–	–	–
3	Random Forest	Non-Fraud	–	–	–	–	–	–	–	–	–	–	–
		Fraud	–	–	–	–	–	–	–	–	–	–	–
3	XGBoost	Non-Fraud	–	–	–	–	–	–	–	–	–	–	–
		Fraud	–	–	–	–	–	–	–	–	–	–	–

Keterangan: Tanda (-) menunjukkan nilai yang akan diisi berdasarkan hasil eksperimen.

Berdasarkan Tabel 3.7, hasil pengujian dari setiap kombinasi skenario dan algoritma dibandingkan untuk mengidentifikasi model dengan performa terbaik. Penentuan model terbaik terutama mempertimbangkan F1-Score dan Recall pada kelas Fraud, dengan tetap memperhatikan Precision serta jumlah kesalahan klasifikasi. PR-AUC juga digunakan untuk mengevaluasi kemampuan model dalam membedakan kelas pada berbagai nilai threshold. Model dan skenario terbaik selanjutnya ditetapkan sebagai proposed model untuk dibandingkan dengan hasil penelitian terdahulu. Perbandingan tersebut dilakukan untuk mengetahui posisi dan hasil pengembangan metode yang diusulkan terhadap pendekatan yang telah diterapkan sebelumnya. Hasil perbandingan disajikan pada Tabel 3.8.

Tabel 3.8 Perbandingan Proposed Model dengan Penelitian Terdahulu

Model	Class	TP	TN	FP	FN	Presisi (%)	Recall (%)	F1-Score (%)	Akurasi (%)	Specificity (%)	ROC-AUC	PR-AUC
Logistic Regression [26]	Fraud Non-Fraud	-	-	-	-	10	86	82	-	-	0,92	0,67

Model	Class	TP	TN	FP	FN	Presisi (%)	Recall (%)	F1-Score (%)	Akurasi (%)	Specificity (%)	ROC-AUC	PR-AUC
Random Forest [27]	Fraud Non-Fraud	-	-	-	-	13,88	85,96	23,90	66,28	-	0,80	0,16
XGBoost [29]	Fraud Non-Fraud	166	3551	89	554	65,10	23,06	34,05	85,25	97,55	-	-
Proposed Method	Fraud Non-Fraud	-	-	-	-	-	-	-	-	-	-	-

Keterangan: Tidak semua penelitian terdahulu melaporkan seluruh metrik evaluasi yang digunakan dalam penelitian ini. Tanda (–) menunjukkan metrik yang tidak dilaporkan atau tidak tersedia pada penelitian terkait. Adapun nilai evaluasi pada Proposed Method belum dicantumkan karena masih menunggu penyelesaian seluruh tahapan eksperimen. Nilai tersebut akan diisi berdasarkan hasil pengujian model yang diusulkan menggunakan seluruh metrik evaluasi yang tercantum pada tabel.

Berdasarkan Tabel 3.8, perbandingan dilakukan dengan mempertimbangkan perbedaan dataset, algoritma, teknik pengolahan data, dan metrik evaluasi yang digunakan. Penelitian Sabado dkk. [26] menjadi pembanding utama karena menggunakan dataset European Credit Card Fraud Detection yang sama. Sementara itu, penelitian Komsrimorakot dan Siriborvornratanakul [27] digunakan sebagai referensi pendukung terkait penerapan teknik resampling pada data fraud yang tidak seimbang. Perbandingan ini digunakan untuk menjelaskan posisi penelitian yang diusulkan, terutama dalam penerapan tiga skenario pengolahan data dan integrasi model klasifikasi dengan Agentic AI sebagai lapisan investigasi dan pendukung pengambilan keputusan.

3.6.4 Pengujian Optimasi Threshold

Setelah diperoleh model dengan performa terbaik berdasarkan hasil pengujian pada ketiga skenario, dilakukan optimasi threshold untuk menentukan batas probabilitas klasifikasi transaksi fraud. Pengujian dilakukan dengan membandingkan penggunaan threshold default sebesar 0,50 dengan beberapa nilai threshold alternatif. Penentuan threshold terbaik dilakukan berdasarkan data validasi dengan mempertimbangkan nilai precision, recall, dan F1-score pada kelas fraud. Threshold terpilih selanjutnya digunakan dalam proses klasifikasi pada sistem Agentic AI. Evaluasi akhir terhadap model dilakukan menggunakan data testing yang tidak digunakan dalam proses pemilihan threshold.

3.7 Lini masa penelitian

Tahap ini merupakan tahap dokumentasi rincian penelitian. Berikut merupakan rancangan waktu pada penelitian yang akan dilakukan, dapat dilihat pada Tabel 3 sebagai berikut:

Tabel 3.9 Lini Masa Penelitian

No.	Kegiatan	Bulan 1	Bulan 2	Bulan 3	Bulan 4
1	Studi literatur dan identifikasi masalah				
2	Pengumpulan dan eksplorasi dataset				
3	Persiapan dan preprocessing data				
4	Implementasi model Machine Learning				
5	Pengujian tiga skenario eksperimen				
6	Optimasi threshold dan evaluasi model				
7	Pengembangan Agentic AI				
8	Integrasi model dengan aplikasi				
9	Pengujian dan evaluasi sistem				
10	Penyusunan paper dan laporan akhir				

Lini masa tersebut merupakan rencana pelaksanaan penelitian yang akan disesuaikan dengan kalender akademik dan tenggat penyelesaian proyek.

DAFTAR PUSTAKA

[1] T. Malone and A. Thomsen, "The digital pivot: Exploring credit card and e-payment utilization in direct-to-consumer US agriculture," *Journal of Small Business Strategy*, vol. 35, no. 2, pp. 52–66, 2025, doi: 10.53703/001c.129666.

[2] G. Das, Y. A. Ali, B. Singh, and K. Nag, "Digital forensics in e-commerce: Investigating online payment fraud and data breaches," *International Journal of Innovations in Science, Engineering and Management*, pp. 262–268, 2025, doi: 10.69968/ijisem.2025v4i1262-268.

[3] S. P. Ngcobo, "Proactive management of lost bank cards," Ph.D. dissertation, Stellenbosch University, Stellenbosch, South Africa, 2026.

[4] J. Sharma, D. Gupta, and P. Yadav, "Mediating role of perceived security and trust between the perception about financial frauds, security awareness and usage of digital payments," *International Journal of Electronic Business*, vol. 22, no. 1, pp. 1–17, 2026, doi: 10.1504/IJEB.2026.155036.

[5] A. Kale and S. Viswanathan, "Global surge in banking frauds: An international management perspective," *International Journal of Accounting and Management Sciences*, vol. 4, no. 4, 2025, doi: 10.56830/IJAMS10202507.

[6] D. N. O. Oliveira, "Neural networks for real-time financial fraud detection," *Journal International Review of Research Studies*, vol. 1, no. 3, pp. 1–49, 2026, doi: 10.66104/xkad2306.

[7] S. Iqbal, K. M. Awan, S. Kamal, and Z. U. Rehman, "Interpretable ensemble learning models for credit card fraud detection," *Applied Sciences*, vol. 15, no. 22, Art. no. 12073, 2025, doi: 10.3390/app152212073.

[8] C. Wang, C. Nie, and Y. Liu, "Evaluating supervised learning models for fraud detection: A comparative study of classical and deep architectures on imbalanced transaction data," *arXiv preprint* arXiv:2505.22521, 2025, doi: 10.48550/arXiv.2505.22521.

[9] A. A. Al-Maari, M. Abdulnabi, Y. Nathan, A. Ali, U. Ali, and M. Khan, "Optimized credit card fraud detection leveraging ensemble machine learning methods," *Engineering, Technology & Applied Science Research*, vol. 15, no. 3, pp. 22287–22294, 2025, doi: 10.48084/etasr.10287.

[10] S. F. Pratama and A. M. A. Wahid, "Fraudulent transaction detection in online systems using random forest and gradient boosting," *Journal of Cyber Law*, vol. 1, no. 1, pp. 88–115, 2025. Available: http://sovereignresearch.org/technema/article/view/34

[11] Y. Xiao, L. Tan, and J. Liu, "Application of machine learning model in fraud identification: A comparative study of CatBoost, XGBoost and LightGBM," *Preprints*, 2025, doi: 10.20944/preprints202503.1199.v1.

[12] K. Kandi and A. García-Dopico, "Enhancing performance of credit card model by utilizing LSTM networks and XGBoost algorithms," *Machine Learning and Knowledge Extraction*, vol. 7, no. 1, Art. no. 20, 2025, doi: 10.3390/make7010020.

[13] L. Andrade-Arenas and C. Yactayo-Arias, “Comparative analysis of machine learning models for credit card fraud detection using SMOTE for class imbalance,” *International Journal of Safety & Security Engineering*, vol. 15, no. 5, Art. no. 893, 2025, doi: 10.18280/ijsse.150504.

[14] F. L. Becerra-Suarez, P. P. Arones-Perez, F. F. Zamora-Del-Aguila, and M. G. Forero, “Conservative plausibility-filtered SMOTE for credit card fraud detection under extreme class imbalance,” *Frontiers in Artificial Intelligence*, vol. 9, Art. no. 1871972, 2026, doi: 10.3389/frai.2026.1871972.

[15] R. K. Gupta *et al.*, “Enhanced framework for credit card fraud detection using robust feature selection and a stacking ensemble model approach,” *Results in Engineering*, vol. 26, Art. no. 105084, 2025, doi: 10.1016/j.rineng.2025.105084.

[16] M. Zlobin and V. Bazylevych, “Development of a preprocessing methodology for imbalanced datasets in machine learning training,” *Technology Audit and Production Reserves*, vol. 3, no. 2 (83), pp. 55–61, 2025, doi: 10.15587/2706-5448.2025.330639.

[17] M. Ajmal, M. Ashraf, and A. Islam, “From intelligent tools to autonomous agents: A conceptual framework for agentic AI in organizational systems,” *Research Consortium Archive*, vol. 4, no. 2, pp. 1415–1432, 2026, doi: 10.5281/zenodo.19920059.

[18] A. Murat *et al.*, “From concept to execution: An AI-agentic decision intelligence framework for product planning and concept development,” in *Proc. 2025 NDIA Michigan Chapter Ground Vehicle Systems Engineering and Technology Symposium*, paper 377537, 2025, doi: 10.4271/2026-01-7533.

[19] K. L. Ogunsusi, T. T. Yussuph, and B. A. Hammed, “FinRisk AgentNet: Multi-agent LLM & ML architecture for agentic fraud risk detection & quantitative financial risk management,” *Journal of Engineering and Computational Intelligence Review*, vol. 3, no. 1, pp. 155–172, 2025, doi: 10.63544/7jgqap02.

[20] S. Shuster, E. Zloof, A. Shabtai, and R. Puzis, “FAA framework: A large language model-based approach for credit card fraud investigations,” *arXiv preprint* arXiv:2506.11635, 2025, doi: 10.48550/arXiv.2506.11635.

[21] S. Ahmad and Y. Alshuaibany, “Implementing AI-driven decision support systems in data management,” *Precision Journal of Information Technology and Scientific Innovation*, vol. 1, no. 1, pp. 1–15, 2026.

[22] T. Sodnomdavaa and G. Lkhagvadorj, “Financial statement fraud detection through an integrated machine learning and explainable AI framework,” *Journal of Risk and Financial Management*, vol. 19, no. 1, Art. no. 13, 2026, doi: 10.3390/jrfm19010013.

[23] E. Btoush, T. Kobbaey, H. Tamimi, and X. Zhou, “Machine learning-based cyber fraud detection: A comparative study of resampling methods for imbalanced credit card data,” *Applied Sciences*, vol. 16, no. 2, Art. no. 850, 2026, doi: 10.3390/app16020850.

[24] E. A. Aldakheel, A. M. Osman, S. Abbas, Y. Fouad, and A. M. Elshewey, “Hybrid generative adversarial network assisted oversampling for credit card fraud detection,” *IEEE Access*, vol. 14, pp. 54828–54845, 2026, doi: 10.1109/ACCESS.2026.3680136.

[25] N. Baisholan, J. E. Dietz, S. Gnatyuk, M. Turdalyuly, E. T. Matson, and K. Baisholanova, “A systematic review of machine learning in credit card fraud detection under original class imbalance,” *Computers*, vol. 14, no. 10, Art. no. 437, 2025, doi: 10.3390/computers14100437.

[26] A. C. B. Sabado, E. R. Yu II, and R. B. Ricafort, “Imbalance-aware evaluation and hyperparameter optimization of supervised machine learning models for credit card fraud detection,” *International Journal of Latest Technology in Engineering, Management & Applied Science*, vol. 15, no. 4, 2026, doi: 10.51583/IJLTEMAS.2026.150400092.

[27] P. Komsrimorakot and T. Siriborvornratanakul, “Enhancing fraud detection in imbalanced motor insurance datasets using CP-SMOTE and random under-sampling,” *Journal of Big Data*, vol. 12, Art. no. 172, 2025, doi: 10.1186/s40537-025-01217-3.

[28] I. Mapfumo and T. Shongwe, “Performance evaluation of machine learning and deep learning models for credit risk prediction,” *Journal of Risk and Financial Management*, vol. 19, no. 3, Art. no. 210, 2026, doi: 10.3390/jrfm19030210.

[29] S. D. Permai and K. Herdianto, “Prediction of health insurance claims using logistic regression and XGBoost methods,” *Procedia Computer Science*, vol. 227, pp. 1012–1019, 2023, doi: 10.1016/j.procs.2023.10.610.

[30] Machine Learning Group, Université Libre de Bruxelles (ULB), “Credit card fraud detection,” *Kaggle*. [Online]. Available: https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud. [Accessed: Oct. 25, 2026].